

Predicción de Régimen de Volatilidad del S&P 500 mediante XGBoost

Documentación Técnica — Trabajo de Fin de Máster

1. Introducción y Motivación

1.1 Contexto

Este trabajo aborda el problema de la predicción en series temporales financieras, concretamente sobre el índice S&P 500 (SP500), el principal índice bursátil de referencia mundial. La pregunta de partida fue amplia: ¿es posible predecir el comportamiento futuro del SP500 a partir de información pasada de múltiples activos financieros?

Para responderla, se realizó un recorrido metodológico completo que comenzó con modelos de forecasting pre-entrenados (Amazon Chronos) y culminó en un sistema de predicción de regímenes de volatilidad con XGBoost, obteniendo resultados sólidos y estadísticamente significativos.

1.2 Activos utilizados

Los datos empleados cubren el periodo **2000-08-30 a 2025-12-31** (6.349 observaciones diarias) y comprenden 9 series temporales de distinta naturaleza:

Activo	Tipo	Correlación con SP500
S&P 500 (SP500)	Índice bursátil USA (target)	1.000
VIX	Índice de volatilidad implícita	-0.732
Nasdaq	Índice bursátil tecnológico	+0.920
Cobre	Commodity industrial	+0.267
Petróleo WTI	Commodity energético	+0.219
Plata	Metal precioso/industrial	+0.119
Gas Natural	Commodity energético	+0.057
Oro	Metal precioso (safe haven)	-0.002
Dólar (DXY)	Índice del dólar USA	-0.101

La matriz de correlación reveló que el VIX es el activo más informativo (correlación -0.73), mientras que Oro y Dólar aportan señal independiente al ser casi ortogonales al SP500. Nasdaq fue excluido del modelo final por redundancia (corr=0.92).

2. Recorrido Metodológico: Del Forecasting a la Clasificación de Volatilidad

2.1 Primer enfoque: Predicción de dirección de precio (Chronos)

Se comenzó evaluando **Amazon Chronos** (`chronos-t5-small`), un modelo Transformer pre-entrenado en Hugging Face para forecasting de series temporales. Se realizó fine-tuning sobre las series de retornos logarítmicos y se evaluó la *Directional Accuracy* (DirAcc) a horizontes de 1, 5 y 20 días.

Horizonte Chronos Naive (predice 0) MASE

h=1d	52.4%	—	0.608
h=5d	53.6%	—	0.608
h=20d	53.0%	—	0.617

El MASE (Mean Absolute Scaled Error) próximo a 0.60 y la DirAcc apenas por encima del 50% indicaron que el modelo no capturaba señal predictiva real.

2.2 Segundo enfoque: LightGBM y XGBoost multivariante

Se construyó un pipeline de features de lag (retornos pasados de todos los activos), indicadores técnicos (RSI, MACD, Bollinger Bands) y variables de régimen de mercado, evaluando LightGBM y XGBoost con optimización de hiperparámetros mediante Optuna.

Modelo	h=20d DirAcc	ROC-AUC
Naive (siempre sube)	67.3%	—
Chronos fine-tuned	53.0%	—
LightGBM	61.4%	~0.55
XGBoost (target >0%)	64.5%–71.0%*	0.448–0.603

*El 71% era un resultado artificioso: el modelo predecía casi siempre "sube" (95% de los casos), lo que explotaba el sesgo alcista del mercado pero no aportaba discriminación real.

2.3 Diagnóstico crítico: El problema del overlapping y la ausencia de señal

Se aplicó **Purged TimeSeriesSplit** (validación cruzada temporal con gap igual al horizonte de predicción) para eliminar el solapamiento entre ventanas de target. El diagnóstico fue concluyente:

Horizonte ROC-AUC purged CV (dirección)

h=1d	0.492 ± 0.012
h=5d	0.495 ± 0.028
h=20d	0.493 ± 0.026

Todos los horizontes dieron ROC-AUC ≈ 0.49 — prácticamente azar. Esto es consistente con la Hipótesis de Mercados Eficientes (EMH) en su forma débil: los retornos diarios del SP500 no son predecibles de forma sistemática a partir de información de precios pasados.

2.4 Cambio de variable objetivo: Volatilidad en lugar de dirección

El mismo experimento diagnóstico reveló que predecir el **régimen de volatilidad futura** sí tiene señal real:

Target	Horizonte	ROC-AUC purged CV
Dirección (>0%)	h=5d	0.495
Dirección (>0%)	h=20d	0.493
Régimen alta/baja vol	h=5d	0.802
Régimen alta/baja vol	h=10d	0.813
Régimen alta/baja vol	h=20d	0.778

Este resultado es coherente con el **efecto ARCH/GARCH** (Engle, 1982; Bollerslev, 1986), uno de los fenómenos más robustos y replicados en econometría financiera: la volatilidad tiende a agruparse en el tiempo (*volatility clustering*), lo que la hace predecible a diferencia de los retornos.

3. Datos y Preprocesamiento

3.1 Fuentes y formato

Los datos se descargaron en formato CSV con estructura de 3 filas de cabecera (formato yfinance), conteniendo columnas Date, Close, High, Low, Open, Volume. Para cada activo se utilizó únicamente el precio de cierre ajustado.

3.2 Transformación a retornos logarítmicos

Los precios se transformaron a retornos logarítmicos diarios. Esta transformación es estándar en finanzas cuantitativas porque: (1) estabiliza la varianza respecto a los precios crudos, (2) convierte la serie en aproximadamente estacionaria, y (3) los retornos son aditivos en el tiempo, lo que facilita la construcción de retornos acumulados.

3.3 División temporal (split)

Se utilizó un **split temporal estricto** sin aleatoriedad para evitar data leakage:

Conjunto	Periodo	Observaciones	Sube (target)
Train	2000-08-31 → 2017-12-29	4.341	49.9%
Validación	2018-01-02 → 2019-12-31	502	56.8%
Test	2020-01-02 → 2025-12-31	1.506	33.8%*

*El porcentaje de "alta volatilidad" en test es 33.8% porque el umbral se fijó en el percentil 70 del train (alta exigencia: solo el 30% superior de volatilidad del periodo 2000-2017 se considera "alta"), y el periodo 2020-2025 incluye fases muy tranquilas que se clasifican como baja volatilidad.

La elección del split fue deliberada: se excluyó el periodo COVID (2019-2021) de la validación después de comprobar que incluirlo sesgaba el threshold de decisión de forma no generalizable (val mostraba 66.4% de clase "sube" vs 56.2% en test, causando ROC-AUC de 0.448 en test).

3.4 Definición del target

El target es una clasificación binaria entre alta volatilidad (1) y baja volatilidad (0) el percentil 70 de la volatilidad futura calculado **exclusivamente sobre el conjunto de train** (evitando leakage). Este umbral equivale a 0.01088 en términos de desviación estándar diaria.

Por qué percentil 70 en lugar de la mediana: usar la mediana generaría un target perfectamente balanceado (50/50) en train pero forzado. El percentil 70 define "alta volatilidad" de forma más intuitiva: se trata del 30% de los días con mayor agitación de mercado, que es cuando la gestión de riesgo es más crítica. Esto refleja mejor la aplicación práctica del modelo.

3.5 Construcción de features

Se construyeron **97 features** a partir de información disponible hasta el momento de predicción (sin leakage futuro), organizadas en 7 categorías:

Lags de retornos (57 features): retornos pasados del SP500 a lags 1-20 y de los 7 activos restantes a lags [1, 2, 3, 5, 10, 15, 20]. Se utilizaron menos lags para activos secundarios para evitar curse of dimensionality dado el tamaño de muestra.

Volatilidad rolling del SP500 (6 features): desviación estándar de retornos a ventanas de 5, 10, 20 y 60 días, más dos ratios de volatilidades (5/20 y 10/60) que capturan si la volatilidad reciente es alta o baja respecto a la histórica.

Momentum (3 features): retorno acumulado del SP500 a 5, 10 y 20 días.

Indicadores técnicos (5 features): RSI a 14 y 28 días, MACD, histograma MACD, y Bandas de Bollinger (%B).

Régimen de mercado (4 features): diferencia EMA50-EMA200 (tendencia largo plazo), distancia al EMA200, z-score a 20 y 60 días (sobreextensión).

Features del VIX (6 features): nivel absoluto del VIX (no solo el retorno), z-score a 60 días, percentil dentro del último año, distancia sobre su media de 20 días, indicador de pánico ($VIX > 30$), y tendencia a 5 días. Estas features resultaron ser de las más importantes según el modelo.

Correlaciones rolling y calendario (4 features): correlación rolling a 30 días SP500-Oro y SP500-VIX, día de la semana y mes del año.

3.6 Normalización

Todas las features se estandarizaron con `StandardScaler` (media=0, std=1), ajustado **exclusivamente sobre train** y aplicado a validación y test. Esto evita que información de test influya en la normalización.

4. Entrenamiento del Modelo

4.1 Elección del algoritmo: XGBoost

Se eligió **XGBoost** (eXtreme Gradient Boosting, Chen & Guestrin, 2016) por varias razones:

- Supera consistentemente a otros algoritmos en datasets tabulares de tamaño moderado (< 10.000 filas), como demuestran los benchmarks de Kaggle y los estudios de Grinsztajn et al. (2022).
- Incorpora regularización L1 (alpha) y L2 (lambda) nativa, crítica con el ratio muestras/features de ~44:1 que teníamos.
- Soporta aceleración GPU (`tree_method="hist"` , `device="cuda"`), reduciendo el tiempo de entrenamiento de horas a minutos. Se han hecho dos pruebas: primero con GPU, después con CPU.
- Los árboles de decisión que lo componen son naturalmente robustos a features irrelevantes, lo que es importante dado que algunas de las 97 features tienen señal débil.

Se descartaron modelos Transformer tabulares (FT-Transformer) por el tamaño de muestra insuficiente (~800 filas tras la purga de solapamiento), y modelos LSTM/RNN por la mayor dificultad de regularización y ajuste.

4.2 Optimización de hiperparámetros con Optuna

Se empleó **Optuna** con el muestreador TPE (Tree-structured Parzen Estimator) para explorar el espacio de hiperparámetros. Se ejecutaron **600 trials** optimizando el **ROC-AUC en validación** (no la accuracy, ya que es más informativa para clasificación con clases desequilibradas).

Los rangos de búsqueda se definieron de forma conservadora dado el tamaño de muestra:

Hiperparámetro	Rango	Valor óptimo
<code>learning_rate</code>	[0.005, 0.1] log-scale	0.0175
<code>max_depth</code>	[2, 5]	3
<code>n_estimators</code>	[50, 800]	737
<code>subsample</code>	[0.5, 0.9]	0.867
<code>colsample_bytree</code>	[0.3, 0.8]	0.765
<code>gamma</code>	[0.1, 5.0]	0.662
<code>lambda</code> (L2)	[0.5, 20.0]	1.17
<code>alpha</code> (L1)	[0.05, 10.0]	1.52
<code>min_child_weight</code>	[10, 50]	34

El modelo final se re-entrenó con los mejores hiperparámetros durante el doble de estimadores con early stopping sobre validación.

4.3 Calibración del threshold de decisión

XGBoost produce probabilidades continuas en [0,1]. El threshold de decisión (por encima del cual se predice clase 1 "alta volatilidad") se buscó exhaustivamente sobre el conjunto de validación en el rango [0.20, 0.81] maximizando la accuracy. El threshold óptimo encontrado fue **0.41**, ligeramente por debajo del 0.5 estándar, lo que refleja que el modelo es ligeramente conservador en sus predicciones de alta volatilidad.

5. Evaluación y Resultados

5.1 Métricas en el conjunto de test

La evaluación final se realizó sobre **1.496 observaciones del periodo 2020-2025**, un periodo que incluye eventos de mercado extremos (crash COVID de marzo 2020, recuperación 2020-2021, mercado bajista 2022, rally de IA 2023-2024) y por tanto constituye una prueba exigente de generalización.

Métrica	Valor
DirAcc (Accuracy)	77.41%
ROC-AUC	0.824
F1-macro	0.509
p-value (test binomial, H0: acc=50%)	< 0.0001
Threshold usado	0.41

5.2 Reporte por clase

Clase	Precision	Recall	F1	Soporte
Volatilidad baja	0.84	0.82	0.83	990
Volatilidad alta	0.66	0.69	0.68	506
Macro avg	0.75	0.75	0.75	1.496

5.3 Matriz de confusión

	Pred. Vol. baja	Pred. Vol. alta
Real Vol. baja	807 (53.9%)	183 (12.2%)
Real Vol. alta	155 (10.3%)	351 (23.4%)

El modelo acierta **807 + 351 = 1.158 de 1.496 observaciones (77.4%)**. Los errores más relevantes para la aplicación práctica son los **155 falsos negativos** (periodos de alta volatilidad no detectados), que representan un 1.3% del total — un nivel aceptable para un sistema de alerta temprana.

5.4 Importancia de features

Las 5 features más importantes según la ganancia de XGBoost (information gain acumulado en los splits de árboles):

Ranking	Feature	Interpretación
1	SP500_vol10	Volatilidad realizada en los últimos 10 días
2	SP500_zscore60	Sobreextensión respecto a la tendencia de 60 días — mercados muy alejados de su media tienden a aumentar volatilidad
3	SP500_vol5	Volatilidad realizada en los últimos 5 días — el efecto ARCH más directo
4	SP500_vol20	Volatilidad realizada en los últimos 20 días
5	Dolar_logret_lag20	Retorno del dólar hace 20 días — señal macro rezagada

El dominio de las features de volatilidad pasada confirma empíricamente el efecto ARCH: la mejor señal para predecir volatilidad futura es la volatilidad pasada reciente.

5.5 Significancia estadística

El p-value del test binomial unilateral (H_0 : accuracy = 50%) es < 0.0001 , descartando con total rotundidad que el resultado sea fruto del azar. Con ROC-AUC = 0.824 y 1.496 observaciones de test, la señal predictiva es estadísticamente sólida y económicamente relevante.

6. Comparativa con Modelos Anteriores

A lo largo del trabajo se evaluaron varios enfoques, que quedan resumidos en la siguiente tabla:

Modelo	Target	DirAcc	ROC-AUC	Señal real (purged CV)
Amazon Chronos (zero-shot)	Dirección h=1d	52.4%	—	No
Amazon Chronos (fine-tuned)	Dirección h=20d	53.0%	—	No
LightGBM	Dirección h=20d	61.4%	~0.55	No
XGBoost v1 (target >0%)	Dirección h=20d	71.0%*	0.603	No*
XGBoost final	Régimen volatilidad h=10d	77.41%	0.824	Sí

*El 71% era aparente: el modelo predecía "sube" en el 95% de los casos explotando el sesgo alcista del mercado. El ROC-AUC de 0.603 indicaba señal débil no robusta.

La diferencia fundamental entre los modelos fallidos y el final no es el algoritmo ni los hiperparámetros — es la **variable objetivo**. Predecir la dirección del precio (un proceso cercano al random walk) es intrínsecamente difícil; predecir el régimen de volatilidad (un proceso con memoria fuerte) es factible.

7. Conclusiones

7.1 Sobre la predictibilidad de los mercados financieros

El trabajo aporta evidencia empírica sobre dos fenómenos bien documentados en la literatura financiera:

Los retornos diarios del SP500 no son predecibles de forma sistemática. Los análisis con **Purged TimeSeriesSplit** mostraron ROC-AUC ≈ 0.49 para todos los modelos y horizontes evaluados en la predicción de dirección de precio. Esto es consistente con la Hipótesis de Mercados Eficientes en forma débil (Fama, 1970): la información histórica de precios ya está incorporada en los precios actuales.

La volatilidad de los retornos sí es predecible. El modelo de régimen de volatilidad alcanzó ROC-AUC = 0.824 en test, confirmando el efecto ARCH/GARCH (Engle, 1982). Los periodos de alta volatilidad tienden a agruparse (volatility clustering), y las features de volatilidad pasada — especialmente la desviación estándar a 5 y 10 días y el z-score a 60 días — son altamente informativas sobre la volatilidad futura.

7.2 Sobre la metodología

La distinción más importante del trabajo metodológicamente es la aplicación de **evaluación con Purged TimeSeriesSplit**, que eliminó el sesgo de solapamiento de ventanas rolling. Este sesgo es frecuentemente ignorado en la literatura aplicada y causó diferencias dramáticas: modelos con accuracy aparente del 67-71% y ROC-AUC de 0.60 revelaron señal casi nula (ROC-AUC $\sim$ 0.49) al aplicar la evaluación correcta.

La **elección de variable objetivo** resultó más determinante que cualquier decisión de arquitectura o hiperparámetros: cambiar de dirección de precio a régimen de volatilidad multiplicó el ROC-AUC por 1.7 (de 0.49 a 0.82).

7.3 Aplicación práctica

El modelo tiene aplicación directa en gestión de carteras y gestión de riesgo:

- **Position sizing dinámico:** reducir la exposición a renta variable cuando el modelo predice alta volatilidad, aumentarla en regímenes de baja volatilidad predicha.
- **Cobertura con opciones:** la predicción de alta volatilidad señala momentos favorables para comprar protección mediante opciones put o futuros sobre VIX.
- **Alertas de riesgo:** el modelo podría implementarse como sistema de alerta temprana en una plataforma de gestión de riesgo institucional.

Con un recall del 66% para la clase de alta volatilidad, el modelo detecta dos de cada tres periodos de alta agitación de mercado con anticipación de hasta 10 días hábiles, proporcionando un margen de tiempo suficiente para ajustar posiciones.

7.4 Limitaciones y trabajo futuro

El modelo presenta varias limitaciones que abren líneas de trabajo futuro:

- **Régimen de test atípico:** el periodo 2020-2025 incluye el crash de COVID, un evento de magnitud histórica excepcional. Sería conveniente evaluar el modelo en periodos históricos anteriores (2000-2008, crisis financiera) para verificar la robustez fuera del periodo de entrenamiento.
 - **Features exógenas adicionales:** variables macroeconómicas (tipos de interés, spreads de crédito, índices de sorpresa económica) podrían mejorar la señal, especialmente para horizontes más largos.
 - **Modelos de ensamble:** combinar XGBoost con modelos GARCH clásicos mediante stacking podría aprovechar las fortalezas de cada enfoque (datos tabulares vs. estructura temporal explícita).
 - **Extensión a otros índices:** la metodología podría aplicarse a otros mercados (EURO STOXX 50, Nikkei, mercados emergentes) para verificar si la señal es específica del SP500 o generalizable.
-

8. Referencias

- Bollerslev, T. (1986). Generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 31(3), 307-327.
 - Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. *KDD '16*, 785-794.
 - Engle, R. F. (1982). Autoregressive conditional heteroscedasticity with estimates of the variance of United Kingdom inflation. *Econometrica*, 50(4), 987-1007.
 - Fama, E. F. (1970). Efficient capital markets: A review of theory and empirical work. *Journal of Finance*, 25(2), 383-417.
 - Grinsztajn, L., Oyallon, E., & Varoquaux, G. (2022). Why tree-based models still outperform deep learning on tabular data. *NeurIPS 2022*.
 - López de Prado, M. (2018). *Advances in Financial Machine Learning*. Wiley.
 - Ansari, A. F., et al. (2024). Chronos: Learning the Language of Time Series. *arXiv:2403.07815*.
-

Documento generado como parte del Trabajo de Fin de Máster. Todos los scripts de código, datos y resultados están disponibles en el repositorio del proyecto.